
LLMs locales

La presente tarea tiene como propósito repasar y poner en práctica conceptos asociados al uso de modelos de lenguaje de gran escala, generación de datos sintéticos y evaluación de salidas generadas por modelos de procesamiento de lenguaje natural. Para ello, se trabajará con tres modelos de lenguaje ejecutados de manera local: LLaMA, Phi y Mistral.

A partir de lo anterior, se pide realizar lo siguiente:

- Instalar y ejecutar localmente tres modelos de lenguaje: LLaMA, Phi y Mistral. Se deberá documentar el entorno utilizado, incluyendo sistema operativo, CPU/GPU disponible, memoria RAM, herramienta de ejecución, versión o variante del modelo utilizada y cualquier configuración relevante para la generación de texto.
- Seleccionar un tópico específico para la generación de datos sintéticos. Algunos ejemplos posibles son: reseñas de productos, comentarios de redes sociales, preguntas frecuentes de soporte técnico, consultas de estudiantes, noticias simuladas, mensajes de atención al cliente, correos clasificados como spam/no spam, o textos etiquetados según sentimiento. El tópico escogido debe estar claramente delimitado y justificado.
- Diseñar un conjunto de prompts para la generación de datos sintéticos. Todos los modelos deberán ser evaluados utilizando los mismos prompts, con el fin de permitir una comparación justa entre ellos. Los prompts deben especificar claramente el tópico, el formato de salida esperado, la cantidad de ejemplos a generar, el idioma, las etiquetas requeridas si corresponde, y las restricciones de calidad, longitud o estilo que se consideren relevantes.
- Generar un dataset sintético utilizando cada uno de los tres modelos locales. Cada modelo deberá generar la misma cantidad de ejemplos. El dataset final deberá almacenarse en un formato de su elección.
- Comparar el desempeño de LLaMA, Phi y Mistral en la tarea de generación de datos sintéticos. La comparación debe considerar al menos los siguientes criterios: coherencia del texto generado, relevancia respecto al tópico, diversidad de los ejemplos y cumplimiento del formato solicitado.
- Presentar un análisis cualitativo y cuantitativo de los resultados obtenidos. Concluir

El diseño, los resultados y el análisis deberán ser presentados a través de un video de una duración máxima de 20 minutos, acompañado de material de apoyo, por ejemplo, una presentación con diapositivas.

Entrega

- La tarea puede desarrollarse en grupos de dos o tres estudiantes.
- La entrega se realizará a través de Canvas en la sección correspondiente. La fecha y hora límite de entrega es el día 3 de Julio a las 23:59. Por cada día de atraso se descontarán 7 décimas.
- Se deberán incluir un github con los códigos y todo el material necesario para poder ejecutar la tarea. Además, se deberá adjuntar el video y la presentación utilizada.
- En caso de sospechas de copia, el profesor podrá realizar una interrogación a los integrantes del grupo.